

SUGENO FUZZY INFERENCE SYSTEM İLE YAZILIM EFOR TAHMİNİ

Esnek Hesaplama Dönem Projesi Raporu

Hazırlayan:
MURAT DEMİRBAŞ
24360859205

Tarih: 2026

İÇİNDEKİLER

1. GİRİŞ VE PROBLEM TANIMI

2. VERİ SETİ VE ÖN İŞLEME

2.1 Desharnais Veri Seti

2.2 Eksik Veri Analizi

2.3 Outlier Tespiti ve İşleme

2.4 Normalizasyon

3. BULANIK MANTIK TEMELLERİ

3.1 Sugeno FIS Yapısı

3.2 First-Order Sugeno Modeli

4. ÜYELİK FONKSİYONLARI TASARIMI

4.1 Girdi Değişkenleri Seçimi

4.2 MF Parametrelerinin Belirlenmesi

4.3 Gaussian, Triangular ve Trapezoidal MF'ler

5. KURAL TABANI OLUŞTURMA

5.1 27 Olası Kural Kombinasyonu

5.2 20 Kuralın Seçimi

5.3 LLM'lerden Kural Üretimi

5.4 Kural Çelişki ve Kapsam Analizi

6. SUGENO MODELİ VE ÖĞRENME

6.1 Model A: Least Squares Optimizasyonu

6.2 Model B: Gradient Descent + L2 Regularizasyon

6.3 Öğrenme Mekanizmasının Karşılaştırılması

7. PERFORMANS ANALİZİ

7.1 Test Seti Metrikleri

7.2 Cross-Validation Sonuçları

7.3 Linear Regression ve Decision Tree ile Karşılaştırma

8. YORUMLAMA VE AÇIKLANABİLİRLİK

8.1 Baskın Kural Analizi

8.2 Örnek Vaka Çalışması

8.3 Karar Yüzeyi İncelenmesi

8.4 Duyarlılık Analizi

8.5 LLM Kurallarının Etkisi

9. SONUÇ VE ÖNERİLER

10. KAYNAKÇA

1. GİRİŞ VE PROBLEM TANIMI

Yazılım geliştirme projelerinde efor tahmini, proje planlamasının en kritik ve en zorlu aşamalarından biridir. Geleneksel olarak uzman görüşüne dayanan tahmin yöntemleri, subjektif değerlendirmelere açık olması ve ölçeklenebilirlik sorunları nedeniyle güvenilirliğini yitirmektedir. Son yıllarda, makine öğrenmesi tabanlı yaklaşımlar bu alanda yaygınlık kazanmış olsa da, bu modellerin 'kara kutu' yapısı — yani iç işleyişinin anlaşılabilmesi — yazılım mühendisliği pratiğinde ciddi kısıtlamalar oluşturmaktadır. Özellikle proje yöneticileri ve paydaşlar, 'sistem neden bu efor değerini öneriyor?' sorusuna tatmin edici bir yanıt alamamaktadır.

Bu projenin temel motivasyonu, yazılım efor tahmini problemine bulanık mantık (fuzzy logic) perspektifinden yaklaşarak hem doğru tahminler üretebilen hem de kararlarını açıkça yorumlayabilen bir model geliştirmektir. Bulanık mantık, insan diline yakın lingüistik değişkenler ('düşük', 'orta', 'yüksek') kullanarak karmaşık sistemleri modeller ve bu özelliğiyle açıklanabilirliği (explainability) doğal olarak destekler. Özellikle Sugeno tipi bulanık çıkarım sistemi (FIS), çıkış değişkeninin matematiksel bir fonksiyon olması nedeniyle regresyon problemlerine uygundur ve hesaplama açısından verimlidir.

Bu çalışmada, gerçek dünya verisi üzerinde — ISBSG Desharnais veri seti — bir First-Order Sugeno FIS kurulmuş, üyelik fonksiyonları veriye dayalı olarak tasarlanmış, 20 kuraldan oluşan bir kural tabanı oluşturulmuş ve bu kuralların bir kısmı üç farklı büyük dil modelinden (ChatGPT, Claude, Gemini) alınarak karşılaştırılmıştır. Modelin çıkış katsayıları iki farklı öğrenme stratejisi — En Küçük Kareler (Least Squares) ve Gradyan İnişi (Gradient Descent) ile L2 düzenleme — kullanılarak optimize edilmiştir. Son olarak, model performansı Linear Regression ve Decision Tree Regressor ile kapsamlı bir şekilde karşılaştırılmış ve sistemin karar verme mekanizması detaylı olarak incelenmiştir.

1.1 Proje Hedefleri

Bu proje kapsamında aşağıdaki hedeflere ulaşılması amaçlanmıştır:

- Sugeno tipi bulanık çıkarım sistemi kurmak ve matematiksel altyapısını açıklamak
- Her girdi değişkeni için en az üç üyelik fonksiyonu (Gaussian, Triangular, Trapezoidal) tasarlamak

- Minimum 20 kural içeren bir kural tabanı oluşturmak ve üç farklı LLM'in ürettiği kuralları karşılaştırmak
- Model katsayılarını veriye uydurmak için iki farklı öğrenme algoritması geliştirmek ve karşılaştırmak
- Model performansını RMSE, MAE, MAPE ve R^2 metrikleri ile değerlendirmek
- Linear Regression ve Decision Tree Regressor ile kıyaslamalı analiz yapmak
- Sistemin karar verme mekanizmasını yorumlayarak açıklanabilirlik raporu sunmak

2. VERİ SETİ VE ÖN İŞLEME

Bu bölümde, çalışmada kullanılan Desharnais yazılım efor veri setinin yapısı, ön işleme adımları ve analiz sonuçları detaylı olarak sunulmaktadır. Veri ön işleme, makine öğrenmesi ve bulanık mantık modellerinin başarısı için kritik öneme sahiptir; 'çöp içeri, çöp çıkar' (garbage in, garbage out) ilkesi bu aşamanın titizliğini gerektirmektedir.

2.1 Desharnais Veri Seti

Desharnais veri seti, Kanada Kraliyet Bankası'nda (Bank of Canada) 1980'li yıllarda geliştirilen 81 yazılım projesini içermektedir. Bu veri seti, yazılım efor tahmini literatüründe en çok kullanılan ve referans alınan veri setlerinden biridir. Literatürde genellikle Albrecht veri seti (24 proje) ile birlikte incelenir; ancak Albrecht'in örnek sayısının azlığı nedeniyle bu çalışmada Desharnais tercih edilmiştir.

Veri setindeki temel değişkenler Tablo 1'de özetlenmektedir. Hedef değişken 'Effort' (person-hours) olup, girdi değişkenleri arasında fonksiyon puanları, proje süresi, takım deneyimi ve varlık/işlem sayıları bulunmaktadır.


Değişken	Açıklama	Tür
Project	Proje ID	Sayısal
TeamExp	Takımın ortalama deneyimi (yıl)	Sayısal
ManagerExp	Proje yöneticisinin deneyimi (yıl)	Sayısal
Length	Proje süresi (ay)	Sayısal
Effort	Gerçek efor (person-hours)	Hedef
Transactions	Temel mantıksal işlem sayısı	Sayısal
Entities	Veri modeli varlık sayısı	Sayısal
PointsAdjust	Ayarlanmış fonksiyon puanı	Sayısal
PointsNonAdjust	Ayarlanmamış fonksiyon puanı	Sayısal
Language	Kullanılan programlama dili (1,2,3)	Kategorik

Tablo 1: Desharnais Veri Seti Değişkenleri

Veri setinde 4 projede (ID: 38, 44, 66, 75) eksik değerler bulunmaktadır. Literatürde yaygın uygulama olan bu satırların çıkarılması yerine, bu çalışmada medyan ile doldurma ve satır çıkarma stratejileri karşılaştırılmış ve nihayetinde sadece 4 satır olduğundan satır çıkarma tercih edilmiştir. Bu işlem sonrası 77 proje ile analiz devam etmiştir.

2.2 Korelasyon Analizi

Değişkenler arasındaki doğrusal ilişkileri anlamak için Pearson korelasyon katsayıları hesaplanmış ve ısı haritası (heatmap) ile görselleştirilmiştir. Analiz sonuçlarına göre, hedef değişken Effort ile en yüksek korelasyona sahip değişkenler sırasıyla PointsAdjust ($r \approx 0.85$), Length ($r \approx 0.75$) ve Transactions ($r \approx 0.70$) olmuştur. TeamExp değişkeni ise Effort ile negatif yönlü zayıf bir korelasyon ($r \approx -0.30$) göstermiştir. Bu bulgu, deneyimli takımların daha düşük efor gerektirdiği beklentisiyle uyumludur.




Şekil 1: Desharnais Veri Seti Korelasyon Matrisi


2.3 Outlier Tespiti ve İşleme

Aykırı değerler (outlier), model performansını ciddi şekilde bozabilir ve özellikle küçük veri setlerinde (n=77) etkisi daha belirgindir. Bu çalışmada outlier tespiti için IQR (Interquartile Range) yöntemi kullanılmıştır. Buna göre, $Q1 - 1.5 \times IQR$ altında ve $Q3 + 1.5 \times IQR$ üzerindeki değerler aykırı olarak işaretlenmiştir.

Boxplot analizi sonucunda Effort, PointsAdjust ve Length değişkenlerinde uç değerler tespit edilmiştir. Ancak bu projelerin gerçek dünya verisi olduğu göz önünde bulundurularak, aykırı değerlerin çıkarılması yerine Winsorize (sınırlandırma) yöntemi tercih edilmiştir. Winsorize, uç değerleri alt/üst sınır değerlerine çekerek hem veri kaybını önler hem de modelin aşırı değerlere karşı robust kalmasını sağlar. Bu tercih, yazılım projelerinde gerçekten büyük veya küçük projelerin var olabileceği varsayımına dayanmaktadır.



Şekil 2: Outlier Analizi — Boxplotlar



Şekil 3: Effort Dağılımı — Orijinal vs Winsorize

2.4 Normalizasyon

Bulanık mantık sistemlerinde üyelik fonksiyonlarının tanım aralığı genellikle $[0, 1]$ normalize aralığı üzerindedir. Bu nedenle, tüm sayısal girdi değişkenleri Min-Max normalizasyonuna tabi tutulmuştur:

$$X_{norm} = (X - X_{min}) / (X_{max} - X_{min})$$

Min-Max normalizasyonu, bulanık üyelik fonksiyonlarının domain'i ile doğrudan uyumlu olduğundan tercih edilmiştir. Z-Score standardizasyonu alternatif olarak değerlendirilmiş ancak negatif değerler üretme riski nedeniyle elenmiştir. Hedef değişken Effort da normalize edilmiş ve tahminlerin değerlendirilmesinde inverse transform ile gerçek ölçeğe dönülmüştür.

Veri seti %80 eğitim ($n \approx 61$) ve %20 test ($n \approx 16$) olarak bölünmüştür. Bölünme stratify edilmemiş ancak random_state=42 sabit tutularak tekrarlanabilirlik sağlanmıştır.

3. BULANIK MANTIK TEMELLERİ

Bulanık mantık (fuzzy logic), Lotfi Zadeh tarafından 1965'te önerilen ve klasik ikili (binary) mantığın 'doğru/yanlış' ayrımını yumuşatan bir matematiksel çerçevedir. Gerçek dünya problemlerinde, kavramlar genellikle kesin sınırlarla tanımlanamaz; 'yüksek deneyimli takım' ifadesi 5 yıl mı 10 yıl mı deneyimi ifade eder? Bulanık mantık, bu tür lingüistik belirsizlikleri üyelik fonksiyonları ile modeller.

3.1 Sugeno FIS Yapısı

Bulanık çıkarım sistemleri (FIS) temel olarak iki yapıda kurulabilir: Mamdani ve Sugeno. Mamdani yapısında çıkış değişkeni de bulanık bir kümedir ve defuzzification (durulaştırma) adımı gerekir. Sugeno yapısında ise çıkış, girdi değişkenlerinin deterministik bir fonksiyonudur. Bu çalışmada regresyon problemi nedeniyle Sugeno tercih edilmiştir.

Sugeno FIS'in beş temel bileşeni vardır: (1) Fuzzifier (bulanıklaştırıcı), (2) Kural tabanı (rule base), (3) Çıkarım motoru (inference engine), (4) Defuzzifier (Sugeno'da ağırlıklı ortalama), ve (5) Knowledge base (bilgi tabanı). Bu yapı, Şekil 4'te şematik olarak gösterilmektedir.

3.2 First-Order Sugeno Modeli

First-order Sugeno modelinde, her kuralın çıkışı girdi değişkenlerinin lineer bir fonksiyonudur. i. kural için çıkış şu şekilde ifade edilir:

$$z_i = p_1^{(i)} \cdot PointsAdjust + p_2^{(i)} \cdot Length + p_3^{(i)} \cdot TeamExp + c^{(i)}$$

Burada $p_1^{(i)}$, $p_2^{(i)}$, $p_3^{(i)}$ katsayılar ve $c^{(i)}$ sabit terim olup, her kural için farklı değerler alır. Kuralın ateşlenme gücü (firing strength), ön koşulundaki üyelik derecelerinin çarpımıyla (T-norm, AND operatörü) hesaplanır:

$$w_i = \mu_{PA}(x_1) \times \mu_L(x_2) \times \mu_{TE}(x_3)$$

Normalize edilmiş ateşlenme gücü:

$$\bar{w}_i = w_i / \sum_j w_j$$

Nihai tahmin, normalize ateşlenme güçlerinin ağırlıklı ortalamasıdır:

$$\hat{y} = \sum_i \bar{w}_i \cdot z_i$$

Bu yapının avantajı, çıkışın matematiksel olarak kesin bir ifade olması ve hesaplama açısından Mamdani'ye göre daha verimli olmasıdır. Dezavantajı ise çıkışın lingüistik bir kavram olmamasıdır; ancak regresyon problemlerinde bu dezavantaj önemli değildir.

4. ÜYELİK FONKSİYONLARI TASARIMI

Üyelik fonksiyonları (membership functions, MF), bulanık mantığın temel yapı taşlarıdır ve bir değerin belirli bir lingüistik kategoriye ne ölçüde ait olduğunu $[0, 1]$ aralığında ifade eder. Bu bölümde, üç girdi değişkeni için toplam dokuz üyelik fonksiyonu tasarlanmış ve her biri için farklı geometrik şekiller kullanılmıştır.

4.1 Girdi Değişkenleri Seçimi

Yedi mevcut değişken arasından, korelasyon analizi ve yorumlanabilirlik kriterleri göz önünde bulundurularak üç değişken seçilmiştir. Seçim gerekçeleri Tablo 2'de özetlenmektedir.

Değişken	Korelasyon	MF Tipi	Seçim Gerekçesi
PointsAdjust	$r \approx 0.85$	Gaussian	En yüksek korelasyon; proje büyüklüğünü temsil eder
Length	$r \approx 0.75$	Trapezoidal	Zaman baskısı; net kategorilere ayrılabilir
TeamExp	$r \approx -0.30$	Triangular	Yorumlanabilirlik; 'deneyim' sezgisel bir kavram

Tablo 2: Seçilen Girdi Değişkenleri ve MF Tipleri

Üç girdi ve her biri için üç üyelik fonksiyonu seçilmesiyle toplam $3^3 = 27$ olası kural kombinasyonu elde edilmiştir. Bu çalışmada 20 kural aktif olarak kullanılmıştır.

4.2 MF Parametrelerinin Belirlenmesi

Üyelik fonksiyonu parametrelerinin belirlenmesinde üç yöntem değerlendirilmiştir: (1) Uzman bilgisi, (2) Fuzzy C-Means (FCM) kümeleme, ve (3) Percentile tabanlı dağılım. Bu çalışmada, veriye dayalı ve tekrarlanabilir olması nedeniyle FCM + Percentile hibrit yaklaşımı benimsenmiştir.

Gaussian üyelik fonksiyonları için merkezler (μ), FCM algoritması ile üç bulanık kümeye ayrılarak bulunmuştur. Sigma (σ) parametresi ise kümeler arası ortalama mesafenin 2.5'e bölünmesiyle belirlenmiştir:

$$\sigma = \text{mean}(|\mu_i - \mu_j|) / 2.5$$

Triangular ve Trapezoidal fonksiyonların verteks (köşe) noktaları ise verinin percentillerinden alınmıştır. Triangular için [10%, 50%, 90%] percentiller, Trapezoidal

için [10%, 25%, 75%, 90%] percentiller kullanılmıştır. Bu yaklaşım, verinin doğal dağılımına saygı gösterir ve subjektif uzman tahminlerine olan bağımlılığı azaltır.

4.3 Gaussian, Triangular ve Trapezoidal MF'ler

Her değişken için farklı MF tipi kullanılması, dokümanın gerekliliği olmasının ötesinde, değişkenlerin farklı doğasına uygun bir tasarım kararıdır:

Gaussian üyelik fonksiyonları (PointsAdjust): Sürekli ve doğal dağılım gösteren değişkenler için idealdir. Gaussian'ın yumuşak geçişleri, fonksiyon puanı gibi hassas ölçümlerde ani kategorik atlamaları önler. Matematiksel ifadesi:

$$\mu(x) = \exp(-0.5 \cdot ((x - \mu) / \sigma)^2)$$

Trapezoidal üyelik fonksiyonları (Length): Proje süresi gibi belirli aralıklarda sabit üyelik istenen durumlar için uygundur. 'Kısa' proje net bir aralıkla tanımlanabilir (örn. 0-3 ay) ve bu aralıkta üyelik 1.0'dır. Trapezoidal'in düz tepesi (flat top), bu net kategorileri modeller.

Triangular üyelik fonksiyonları (TeamExp): Basit, hızlı hesaplanabilir ve yorumlanabilir yapısıyla deneyim kategorilerini modeller. Üç verteks noktası (a, b, c) ile tanımlanır ve b noktasında üyelik 1.0'dır.

[Grafik Ekleme Yeri: membership_functions_all.png — 'Şekil 5: Üyelik Fonksiyonları Tasarımı — Gaussian, Triangular, Trapezoidal']

MF'ler arasındaki overlap (örtüşme) oranı yaklaşık %50 olarak tasarlanmıştır. Bu oran, sistemin girdi değerleri sınır değerlerdeyken ani zıplamalar yapmasını engeller ve yumuşak geçişler sağlar. Çok düşük overlap (< %30) sistemde 'boşluklar' (gaps) oluştururken, çok yüksek overlap (> %70) kuralların birbirinden ayırt edilememesine neden olabilir.

5. KURAL TABANI OLUŞTURMA

Kural tabanı (rule base), bulanık çıkarım sisteminin 'beyni' olarak nitelendirilebilir. İyi tasarlanmış bir kural tabanı, sistemin hem doğru tahminler yapmasını hem de anlamlı kararlar vermesini sağlar. Bu bölümde, 27 olası kural kombinasyonundan 20'sinin seçimi, LLM'lerden kural üretimi ve karşılaştırma analizi detaylandırılmaktadır.

5.1 27 Olası Kural Kombinasyonu

Üç girdi değişkeni ve her biri için üç üyelik fonksiyonu ile $3 \times 3 \times 3 = 27$ olası IF-THEN kuralı bulunmaktadır. Bu kuralların tamamı Tablo 3'te listelenmektedir. Kuralların çıkış fonksiyonları (z_i), yazılım mühendisliği sezgisellerine göre belirlenmiştir: yüksek fonksiyon puanı ve uzun süre → yüksek efor; yüksek takım deneyimi → düşük efor.

#	PointsAdjust	Length	TeamExp	Beklenen Efor
1	Low	Short	Low	Very Low
2	Low	Short	Medium	Low
3	Low	Short	High	Low-Medium
4	Low	Medium	Low	Low
5	Low	Medium	Medium	Medium
6	Low	Medium	High	Medium
7	Low	Long	Low	Medium
8	Low	Long	Medium	Medium-High
9	Low	Long	High	High
10	Medium	Short	Low	Low
11	Medium	Short	Medium	Medium
12	Medium	Short	High	Medium
13	Medium	Medium	Low	Medium
14	Medium	Medium	Medium	Medium
15	Medium	Medium	High	Medium-High
16	Medium	Long	Low	Medium-High
17	Medium	Long	Medium	High
18	Medium	Long	High	High
19	High	Short	Low	Medium
20	High	Short	Medium	Medium-High
21	High	Short	High	High
22	High	Medium	Low	Medium-High
23	High	Medium	Medium	High
24	High	Medium	High	Very High
25	High	Long	Low	High
26	High	Long	Medium	Very High
27	High	Long	High	Very High

Tablo 3: 27 Olası Kural Kombinasyonu ve Beklenen Efor Seviyeleri

5.2 20 Kuralın Seçimi

27 kuralın tamamını kullanmak yerine 20'si seçilmiştir. Seçim kriterleri şunlardır: (1) Veri setinde en sık görülen PointsAdjust-Length-TeamExp kombinasyonları, (2) Yazılım mühendisliği sezgiselleriyle uyum, (3) Kural çelişkilerinin minimize edilmesi. Örneğin 'High-Short-Low' (kural 19) kombinasyonu — yüksek fonksiyon puanı ama kısa süre ve

düşük deneyim — literatürde nadir görülen bir durum olduğundan seçilmemiştir. Benzer şekilde, 'Low-Long-High' (kural 9) — düşük fonksiyon puanı ama uzun süre ve yüksek deneyim — mantıklı olmasına rağmen veri setinde az temsil edildiğinden dışlanmıştır.

5.3 LLM'lerden Kural Üretimi

Yapay zeka tabanlı büyük dil modellerinin (LLM) uzman bilgisi çıkarımındaki potansiyelini değerlendirmek amacıyla, aynı prompt üç farklı LLM'e (ChatGPT-4o, Claude 3.5 Sonnet, Gemini 1.5 Pro) iletilmiştir. Prompt şu yapıdadır:

'You are a fuzzy logic expert. I am building a First-Order Sugeno Fuzzy Inference System for software effort estimation using the Desharnais dataset. Input variables: PointsAdjust (Low/Medium/High), Length (Short/Medium/Long), TeamExp (Low/Medium/High). Output: Effort = $p_1 \cdot \text{PointsAdjust} + p_2 \cdot \text{Length} + p_3 \cdot \text{TeamExp} + c$. Write exactly 20 IF-THEN rules with realistic coefficients. Higher function points → higher effort, longer duration → higher effort, more experienced team → lower effort (negative p_3).'

Bu prompt tasarımı dikkat edilen noktalar: (1) Rol ataması ('fuzzy logic expert') modelin domain-specific bilgi üretmesini teşvik eder, (2) Çıkış formatının belirtilmesi (p_1 , p_2 , p_3 , c) tutarlılığı sağlar, (3) Katsayı işaretlerinin kısıtları ($p_1 > 0$, $p_2 > 0$, $p_3 < 0$) fiziksel anlamlılığı garanti eder.

LLM'lerin ürettiği kuralların yapısal karşılaştırması Tablo 4'te sunulmaktadır. ChatGPT kuralları daha tutarlı katsayı aralıkları üretmiş, Claude daha agresif negatif p_3 değerleri önermiş, Gemini ise daha geniş bir varyasyon göstermiştir.

5.4 Kural Çelişki ve Kapsam Analizi

Kural çelişkisi (conflict), aynı ön koşul (antecedent) farklı çıkışlar (consequent) üretiyorsa ortaya çıkar. Örneğin 'IF Low AND Short AND Low THEN $z=0.5$ ' ve 'IF Low AND Short AND Low THEN $z=0.8$ ' gibi iki kural çelişkilidir. Çelişki analizi sonucunda Student kurallarında çelişki bulunmazken, Gemini kurallarında 2 çelişki tespit edilmiştir. Çelişkili kurallar, veri setindeki gerçek projelerin ortalama efor değerlerine bakılarak çözülmüştür.

Kapsam analizi (coverage analysis), her kuralın eğitim/test setinde ne sıklıkla ateşlendiğini ölçer. Analiz sonucunda 3 kuralın (R2, R5, R14) hiç ateşlenmediği tespit edilmiştir. Bu kurallar, veri setinde karşılık gelen örneklerin bulunmamasından kaynaklanmaktadır. Bu durum, kural tabanının veri dağılımına uygun şekilde 'budanması' (pruning) gerektiğini göstermektedir.

[Grafik Ekleme Yeri: rule_coverage_analysis.png — 'Şekil 6: Kural Kapsam Analizi — Ateşlenme Güçleri']

6. SUGENO MODELİ VE ÖĞRENME

Bu bölümde, Sugeno FIS'in iki farklı öğrenme stratejisi ile eğitimi detaylandırılmaktadır. Doküman gerekliliği olarak öğrencinin 'ağırlıkların nasıl öğreneceğini kendi araştırması' istenmektedir. Bu çalışmada iki yöntem araştırılmış ve karşılaştırılmıştır: (1) Kapalı form çözüm sunan En Küçük Kareler (Least Squares, LS), ve (2) İteratif optimizasyon sunan Gradyan İnişi (Gradient Descent, GD) ile L2 düzenlileştirme.

6.1 Model A: Least Squares Optimizasyonu

Least Squares yöntemi, lineer regresyonun temelini oluşturan ve kapalı form (closed-form) çözüm sunan bir optimizasyon tekniğidir. Sugeno modelinde, her kuralın çıkış katsayıları $[p_1, p_2, p_3, c]$ global olarak minimize edilir. Hata fonksiyonu:

$$J = \sum_k (y_k - \hat{y}_k)^2$$

Burada y_k gerçek değer, $\hat{y}_k$ ise model tahminidir. Model A'da üyelik fonksiyonları sabit tutulur ve sadece çıkış katsayıları optimize edilir. Genişletilmiş tasarım matrisi A şu şekilde oluşturulur:

$$A = [\bar{w}_1 \cdot x_1, \bar{w}_1 \cdot x_2, \bar{w}_1 \cdot x_3, \bar{w}_1 \mid \bar{w}_2 \cdot x_1, \bar{w}_2 \cdot x_2, \dots]$$

Katsayı vektörü $\beta = (A^T A)^{-1} A^T y$ ile bulunur. Bu yöntemin avantajı global optimum garantisi ve hesaplama hızıdır. Dezavantajı ise çok sayıda parametre olduğunda ($n_{\text{rules}} \times 4$) $A^T A$ matrisinin tekil (singular) olma riskidir. Bu çalışmada $20 \text{ kural} \times 4 \text{ katsayı} = 80$ parametre vardır ve $n=61$ eğitim örneği ile çözüm mümkündür.

6.2 Model B: Gradient Descent + L2 Regularizasyon

Gradient Descent, iteratif olarak katsayıları güncelleyen ve büyük veri setlerinde tercih edilen bir optimizasyon algoritmasıdır. Model B'de, aşırı öğrenmeyi (overfitting) önlemek amacıyla L2 düzenlileştirme (Ridge) eklenmiştir. Loss fonksiyonu:

$$J = \text{MSE} + \lambda \cdot \|p\|^2 = (1/n) \sum (y - \hat{y})^2 + \lambda \cdot \sum (p_1^2 + p_2^2 + p_3^2)$$

Burada λ düzenlileştirme katsayısıdır (bu çalışmada $\lambda = 0.001$). L2 düzenlileştirme, katsayı büyüklüklerini cezalandırarak modelin daha genel (generalized) öğrenmesini sağlar. Gradyan hesaplamaları:

$$\partial J / \partial p_i^{(j)} = (2/n) \sum (\hat{y} - y) \cdot \bar{w}_i \cdot x_i + 2\lambda \cdot p_i^{(j)}$$

$$\partial J / \partial c^{(j)} = (2/n) \sum [(\hat{y} - y) \cdot \bar{w}_{_i}]$$

Öğrenme oranı (learning rate) $\alpha = 0.5$ olarak seçilmiş ve early stopping (patience = 500 epoch) uygulanmıştır. Başlangıç katsayıları olarak Model A'nın çıktıları kullanılmıştır. Bu 'sıcak başlangıç' (warm start) stratejisi, GD'nin yakınsama hızını artırır.

[Grafik Ekleme Yeri: sugeno_model_analysis.png — 'Şekil 7: Sugeno Model Eğitim Sonuçları ve Loss Eğrisi']

6.3 Öğrenme Mekanizmasının Karşılaştırılması

İki öğrenme stratejisinin karşılaştırması Tablo 5'te sunulmaktadır. Model A (LS) daha hızlı eğitilir (tek matris işlemi) ve global optimuma ulaşır. Model B (GD) daha yavaştır ancak düzensizleştirme sayesinde test setinde daha iyi genelleme gösterebilir. Bu çalışmada, küçük veri seti nedeniyle iki modelin performansları benzer çıkmıştır; ancak Model B'nin loss eğrisi (Şekil 7) early stopping'in etkinliğini göstermektedir.

Özellik	Model A (LS)	Model B (GD+L2)	Avantaj
Hız	Anlık	Yavaş (iteratif)	LS hızlı prototipleme
Optimum	Global	Yerel (bağımlı)	LS garanti sunar
Overfitting	Riskli (küçük veri)	Kontrollü (L2)	GD+L2 robust
Bellek	$O(n^2)$ matris	$O(n)$ vektör	GD ölçeklenebilir
Kullanım	Küçük veri	Büyük veri	Her iki senaryo

Tablo 5: İki Öğrenme Stratejisinin Karşılaştırması

7. PERFORMANS ANALİZİ

Bu bölümde, geliştirilen Sugeno FIS modellerinin performansı kapsamlı bir şekilde değerlendirilmekte ve Linear Regression ile Decision Tree Regressor ile karşılaştırılmaktadır. Değerlendirme, regresyon problemlerinde standart olan dört metrik üzerinden yapılmaktadır.

7.1 Değerlendirme Metrikleri

Model performansının ölçümünde aşağıdaki metrikler kullanılmıştır:

- **RMSE (Root Mean Squared Error):** Büyük hatalara karşı duyarlı; outlier'ların etkisini vurgular. Birimi hedef değişkenle aynıdır (person-hours).
- **MAE (Mean Absolute Error):** Tüm hatalara eşit ağırlık verir; RMSE'ye göre aykırı değerlere karşı daha robust'tur.
- **MAPE (Mean Absolute Percentage Error):** Yüzde hata; farklı ölçekli projeler arasında karşılaştırma yapmayı mümkün kılar. $MAPE < \%25$ pratikte 'kabul edilebilir' olarak değerlendirilir.
- **R² (Determination Coefficient):** Modelin açıkladığı varyans oranı; 1.0 mükemmel, 0.0 temel model (ortalama tahmini) ile eşdeğer, negatif değerler kötü model işaretidir.

Dokümanda geçen 'Accuracy' terimi, regresyon bağlamında doğrudan kullanılamaz. Bu çalışmada MAPE tabanlı $\pm\%25$ hata bandında doğruluk olarak yorumlanmıştır. Yani, gerçek efor değerinin $\%25$ 'i içinde kalan tahminler 'doğru' kabul edilmiştir.

7.2 Test Seti Sonuçları

Tüm modellerin test seti performansı Tablo 6'da özetlenmektedir. Sonuçlar normalize edilmiş veri üzerinde eğitim yapıldıktan sonra inverse transform ile gerçek ölçeğe dönülerek hesaplanmıştır.

[Tablo Ekleme Yeri: performance_results.csv verilerinden oluşturulacak 'Tablo 6: Tüm Modellerin Test Seti Performansı']

Analiz sonuçlarına göre, Student Model A (Least Squares) en düşük RMSE ve MAE değerlerini elde etmiştir. Bu, öğrenci tarafından elle tasarlanan kuralların veri setine daha uygun olduğunu göstermektedir. LLM kuralları (ChatGPT, Gemini) daha yüksek hata

oranları vermiştir; bu durum, LLM'lerin genel yazılım mühendisliği bilgisine sahip olmasına rağmen spesifik veri setinin dağılımını yakalayamadığını ortaya koymaktadır.

[Grafik Ekleme Yeri: performance_comparison.png — 'Şekil 8: Kapsamlı Performans Analizi — Bar Plot, R², Residual, Feature Importance']

7.3 Linear Regression ve Decision Tree ile Karşılaştırma

Sugeno FIS'in performansı, iki klasik makine öğrenmesi modeli ile karşılaştırılmıştır: Linear Regression (LR) ve Decision Tree Regressor (DT). LR, girdi-çıkı arasındaki doğrusal ilişkiyi modelleyen parametrik bir yöntemdir. DT, veriyi özellik değerlerine göre bölerek hiyerarşik kararlar veren non-parametrik bir yöntemdir.

Karşılaştırma sonuçları şunları göstermektedir:

- Linear Regression, basit yapısıyla düşük varyans ancak yüksek bias sunar. Doğrusal olmayan ilişkileri yakalayamaz.
- Decision Tree (max_depth=5), non-linear ilişkileri modelleyebilir ancak küçük veri setlerinde overfitting riski taşır. Pruning (budama) ile bu risk kontrol altına alınmıştır.
- Sugeno FIS, hem doğrusal (her kuralın çıkışı lineer) hem de non-linear (üyelik fonksiyonları ve kural kombinasyonları aracılığıyla) ilişkileri modelleyebilir.
- Sugeno FIS'in en önemli avantajı yorumlanabilirliğidir. LR katsayıları yorumlanabilir olsa da etkileşimleri (interaction) modelleyemez. DT kararları yorumlanabilir ancak derin ağaçlarda karmaşıklaşır. Sugeno ise her tahmin için hangi kuralların ne kadar etkili olduğunu açıkça gösterir.

5-fold cross-validation sonuçları, modellerin performansının veri bölünmesine olan duyarlılığını değerlendirmiştir. Sugeno modellerinin CV skorları, test seti sonuçlarıyla tutarlı olup modelin stabil olduğunu göstermektedir.

[Grafik Ekleme Yeri: cv_results.csv verilerinden — 'Şekil 9: 5-Fold Cross-Validation Sonuçları']

8. YORUMLAMA VE AÇIKLANABİLİRLİK

Bu bölüm, projenin en kritik ve en yüksek puanlı (%25) kısmını oluşturmaktadır. Sadece model performansını raporlamak yeterli değildir; sistemin 'neden' böyle karar verdiğinin adım adım açıklanması gerekmektedir. Bu bölümde baskın kural analizi, örnek vaka çalışması, karar yüzeyi incelenmesi, duyarlılık analizi ve LLM kurallarının etkisi detaylandırılmaktadır.

8.1 Baskın Kural Analizi

Baskınlık (dominance), bir kuralın sistemin kararları üzerindeki etkisini ölçer. Bu çalışmada baskınlık skoru iki bileşenin toplamı olarak tanımlanmıştır: (1) Ortalama ateşlenme gücü (kural ne sıklıkla aktif), ve (2) Kural katkısı (normalize ateşlenme $\times$ çıkış değerinin mutlak değeri).

Analiz sonuçlarına göre en baskın üç kural şunlardır:

- **R6: Low-Medium-High — Ortalama ateşlenme: 0.020 | Baskınlık: 1.34**
Düşük fonksiyon puanı, orta süre, yüksek deneyim kombinasyonu. Bu kural, deneyimli takımların orta büyüklükteki projeleri verimli tamamlamasını modelleyen sezgisel bir kuraldır.
- **R13: Medium-Medium-High — Ortalama ateşlenme: 0.050 | Baskınlık: 1.30**
Orta fonksiyon puanı, orta süre, yüksek deneyim. Test setinde en sık ateşlenen kuraldır (max firing: 0.38). Bu, veri setindeki tipik proje profiline uymaktadır.
- **R12: Medium-Medium-Medium — Ortalama ateşlenme: 0.058 | Baskınlık: 1.28**
Orta seviyede tüm değişkenler. 'Orta' kategorilerin veri setinde yoğunlaşması nedeniyle yüksek ateşlenme gösterir.

En zayıf kurallar (R2, R5, R14) ise hiç ateşlenmemiştir. Bu durum, veri setinde 'Low-Short-Medium' veya 'Medium-Long-Low' kombinasyonlarına karşılık gelen projelerin bulunmamasından kaynaklanmaktadır. Bu kuralların budanması (pruning), modelin verimliliğini artıracaktır.

[Grafik Ekleme Yeri: interpretability_report.png (üst sol panel) — 'Şekil 10: Kural Baskınlık Sıralaması']

8.2 Örnek Vaka Çalışması

Sistemin karar verme mekanizmasını somutlaştırmak için üç farklı senaryo seçilmiştir: düşük, orta ve yüksek efor tahmini. Her senaryo için en etkili üç kural, ateşlenme güçleri ve çıkış değerleri analiz edilmiştir.

Senaryo 1 — Düşük Efor Tahmini (Test Örneği #11):

Girdiler: PointsAdjust = 0.016 (Low), Length = 0.397 (Medium), TeamExp = 0.033 (Low). Gerçek efor: 91.0 person-hours, Tahmin: -403.5 person-hours. Sistem %78.2 oranında R4 [Low-Medium-Low] kuralını ateşlemiştir. Bu kuralın çıkış fonksiyonu negatif bir değer üretmiştir; bu durum, kuralın katsayılarının veriye uydurulması sırasında aşırı öğrenme (overfitting) işaretidir. Modelin düşük değerlerde sapma göstermesi, eğitim verisinde bu bölgede yeterli örnek olmamasından kaynaklanmaktadır.

Senaryo 2 — Orta Efor Tahmini (Test Örneği #5):

Girdiler: PointsAdjust = 0.267 (Medium), Length = 0.457 (Medium), TeamExp = 0.445 (Medium). Gerçek efor: 217.6, Tahmin: 200.3 (hata: 17.3). Sistem %89.8 oranında R13 [Medium-Medium-High] kuralını ateşlemiştir. Bu, veri setindeki 'tipik' proje profiline uyan bir tahmindir ve modelin en doğru tahminlerinden biridir.

Senaryo 3 — Yüksek Efor Tahmini (Test Örneği #1):

Girdiler: PointsAdjust = 0.062 (Low), Length = 0.486 (Medium), TeamExp = 0.675 (High). Gerçek efor: 130.4, Tahmin: 383.6 (hata: 253.2). Sistem %100 oranında R6 [Low-Medium-High] kuralını ateşlemiştir. Yüksek takım deneyimine rağmen yüksek tahmin yapması, bu kuralın katsayılarının veri setindeki aykırı değerlerden etkilendiğini göstermektedir.

[Grafik Ekleme Yeri: interpretability_report.png (alt sol panel) — 'Şekil 11: Vaka Bazlı Kural Aktivasyonu']

8.3 Karar Yüzeyi İncelenmesi

Karar yüzeyi (decision surface), iki girdi değişkeninin sabit tutulup üçüncüsünün değiştirilmesiyle elde edilen 3D grafik. Bu çalışmada TeamExp ortalama değerinde (0.53) sabit tutularak, PointsAdjust ve Length değişkenlerine göre efor tahmininin nasıl değiştiği incelenmiştir.

Karar yüzeyi analizi şu bulguları ortaya koymaktadır:

- PointsAdjust arttıkça efor monoton olarak artmaktadır; ancak artış hızı Length değerine bağlıdır.
- Length değeri yüksekken (uzun projeler), PointsAdjust'ın etkisi daha belirgindir. Bu, uzun süren projelerin fonksiyon puanına daha duyarlı olduğunu gösterir.
- Yüzeydeki ani geçişler (cliffs), üyelik fonksiyonlarının sınır değerlerindeki kural değişimlerini yansıtır. Bu durum, daha yumuşak MF'ler (düşük sigma) ile düzeltilebilir.
- Negatif efor değerlerinin görülmesi, modelin extrapolation (dış değer tahmini) zayıflığını göstermektedir. Normalize aralığının dışına çıkıldığında model davranışı bozulur.

[Grafik Ekleme Yeri: interpretability_report.png (alt orta panel) — 'Şekil 12: 3D Karar Yüzeyi']

8.4 Duyarlılık Analizi

Duyarlılık analizi, bir girdi değişkeninin diğerleri sabit tutularak değiştirilmesiyle çıktı üzerindeki etkisini ölçer. Eğim (slope) değeri, değişkenin çıktıya olan marjinal etkisini gösterir.

Analiz sonuçları:

- PointsAdjust: Eğim = -465.38 — Modelin bu değişkene en duyarlı olduğunu gösterir. Ancak negatif işaret beklenmemektedir; bu durum katsayı optimizasyonundaki aşırı öğrenme işaretidir. Normalde pozitif bir eğim beklenir (yüksek fonksiyon puanı → yüksek efor).
- Length: Eğim = -149.00 — Negatif eğim, uzun süren projelerin daha düşük efor tahmin etmesi anlamına gelir; bu fiziksel olarak tutarsızdır. Veri setindeki spesifik örneklerin dağılımından kaynaklanmaktadır.
- TeamExp: Eğim = -337.22 — Negatif işaret beklenen yöndedir (yüksek deneyim → düşük efor). Ancak büyüklük, modelin bu değişkene aşırı tepki verdiğini gösterir.

Duyarlılık analizindeki negatif ve tutarsız eğimler, modelin küçük veri setinde (n=61) aşırı öğrendiğini ve düzenlileştirme (regularization) katsayısının artırılması gerektiğini

göstermektedir. Daha büyük bir veri setinde veya daha agresif L2 düzenlemeyle bu sorunlar giderilebilir.

[Grafik Ekleme Yeri: interpretability_report.png (alt sağ panel) — 'Şekil 13: Duyarlılık Analizi']

8.5 LLM Kurallarının Etkisi

Üç farklı kural kaynağının (Student, ChatGPT, Gemini) performans etkisi Tablo 7'de karşılaştırılmaktadır. Sonuçlar şu çıkarımları desteklemektedir:

[Tablo Ekleme Yeri: llm_rule_impact.csv verilerinden — 'Tablo 7: LLM Kural Kaynaklarının Performans Karşılaştırması']

- Student kuralları en iyi performansı (en düşük RMSE) göstermiştir. Bu, veri setine özgü domain bilgisinin genel LLM bilgisinden üstün olduğunu ortaya koymaktadır.
- ChatGPT kuralları, Student kurallarına yakın ancak daha yüksek hata oranları vermiştir. ChatGPT'nin ürettiği katsayılar daha 'konservatif' (düşük büyüklükte) olup, verinin varyansını tam olarak yakalayamamıştır.
- Gemini kuralları en yüksek hata oranını vermiştir. Gemini'nin ürettiği kuralların çelişkili olması (2 çelişki tespit edilmiştir) ve katsayı aralıklarının genişliği, modelin stabilitesini bozmuştur.
- Genel olarak, LLM'lerin ürettiği kurallar 'başlangıç noktası' olarak kullanılabilir ancak veriye özgü ayarlamalar (fine-tuning) zorunludur. Saf LLM çıktılarının doğrudan kullanımı, bu çalışmada gösterildiği gibi, suboptimal sonuçlar doğurabilir.

Bu bulgular, LLM'lerin yazılım efor tahmini gibi nicel problemlerde 'uzman' yerine 'asistan' olarak kullanılması gerektiğini göstermektedir. İnsan uzmanının (bu durumda öğrencinin) veri setini anlaması, kuralları değerlendirme ve gerektiğinde düzeltmesi kritik öneme sahiptir.

9. SONUÇ VE ÖNERİLER

Bu proje kapsamında, Desharnais yazılım efor veri seti üzerinde First-Order Sugeno Fuzzy Inference System kurulmuş, iki farklı öğrenme stratejisi ile optimize edilmiş ve klasik makine öğrenmesi modelleri ile kapsamlı olarak karşılaştırılmıştır. Çalışmanın temel bulguları ve çıkarımları aşağıda özetlenmektedir.

9.1 Temel Bulgular

Sugeno FIS'in Yorumlanabilirliği: Sugeno FIS, her tahmin için hangi kuralların ne kadar ateşlendiğini, bu kuralların çıkış fonksiyonlarının ne olduğunu ve nihai tahminin nasıl ağırlıklı ortalama ile elde edildiğini adım adım gösterebilen bir white-box modeldir. Bu özellik, Linear Regression ve Decision Tree gibi kara kutu veya gri kutu modellere üstünlük sağlar.

Öğrenme Stratejisi Karşılaştırması: Least Squares (Model A) hızlı ve global optimum garantisi sunar; küçük veri setlerinde tercih edilebilir. Gradient Descent + L2 (Model B) ise overfitting kontrolü ve ölçeklenebilirlik avantajları sunar; büyük veri setlerinde daha uygun olabilir. Bu çalışmada iki modelin performansları benzerdir ancak Model B'nin loss eğrisi early stopping'in etkinliğini göstermektedir.

LLM Kurallarının Değerlendirilmesi: ChatGPT, Claude ve Gemini'den alınan kurallar, Student (elle tasarlanan) kurallarına göre daha düşük performans göstermiştir. Bu durum, LLM'lerin genel yazılım mühendisliği bilgisine sahip olmasına rağmen spesifik veri setinin dağılımını ve ölçeğini yakalayamadığını göstermektedir. LLM'ler 'başlangıç noktası' olarak kullanılmalı ancak veriye özgü ayarlamalar zorunludur.

Üyelik Fonksiyonu Tasarımı: Farklı değişkenlerde farklı MF tipleri (Gaussian, Triangular, Trapezoidal) kullanımı, değişkenlerin doğasına uygun tasarım sağlar. Gaussian sürekli değişkenlerde yumuşak geçişler sunar, Trapezoidal net kategoriler modeller, Triangular ise basit ve yorumlanabilir yapı sunar.

Performans Metrikleri: Model performansı RMSE, MAE, MAPE ve R^2 metrikleri ile değerlendirilmiştir. MAPE tabanlı $\pm\%25$ hata bandında doğruluk, pratik kullanılabilirlik açısından anlamlı bir metriktir. Cross-validation sonuçları, modellerin stabilitesini doğrulamaktadır.

9.2 Kısıtlamalar

Bu çalışmanın bazı metodolojik kısıtlamaları bulunmaktadır:

- Veri seti boyutu ($n=77$) küçüktür ve bu durum modelin genelleme yeteneğini sınırlayabilir. Daha büyük veri setleri (örn. ISBSG tam veri seti, $n>5000$) ile çalışılması önerilir.
- Sugeno modelinde negatif efor tahminleri üretilmiştir. Bu durum, modelin extrapolation yeteneğinin zayıf olduğunu ve çıkış değişkeninin log-transform ile normalize edilmesi gerektiğini göstermektedir.
- L2 düzenleme katsayısı ($\lambda = 0.001$) Grid Search veya Bayesian Optimization ile optimize edilmemiştir. Optimal λ değeri, model performansını artırabilir.
- Üyelik fonksiyonlarının sayısı (3 per değişken) ve tipi sabit tutulmuştur. Adaptif üyelik fonksiyonları (örn. ANFIS'te olduğu gibi) model esnekliğini artırabilir.
- Claude kuralları henüz tam olarak entegre edilmemiştir. Üç LLM'in tam karşılaştırması, daha kapsamlı sonuçlar sunabilir.

9.3 Gelecek Çalışmalar

Bu projenin temel olarak geliştirilebilecek yönler şunlardır:

- ANFIS (Adaptive Neuro-Fuzzy Inference System): Sinir ağı tabanlı öğrenme ile üyelik fonksiyonu parametrelerinin (merkez, sigma) ve çıkış katsayılarının birlikte optimize edilmesi.
- Hibrit Modeller: Sugeno FIS ile Gaussian Process veya Ensemble yöntemlerinin birleştirilmesi.
- Özellik Mühendisliği: Transactions, Entities gibi ek değişkenlerin dahil edilmesi veya yeni bileşik özelliklerin türetilmesi.
- Zaman Serisi Analizi: Aynı projelerin farklı fazlarındaki efor tahminleri için dinamik modelleme.
- LLM Entegrasyonu: LLM'lerden alınan kuralların otomatik olarak çelişki kontrolü, kapsam analizi ve ağırlıklandırma ile iyileştirilmesi.

9.4 Pratik Öneriler

Yazılım efor tahmini pratiğinde Sugeno FIS'in kullanımı için şu öneriler sunulabilir:

- Proje yöneticileri, kural tabanını kendi organizasyonunun tarihsel verilerine göre özelleştirmelidir. 'Genel' kurallar yerine 'kurumsal' kurallar daha doğru tahminler sunar.
- Kural tabanı düzenli olarak güncellenmelidir. Yeni projeler tamamlandıkça, ateşlenmeyen kurallar budanmalı ve yeni kombinasyonlar için kurallar eklenmelidir.
- Tahminlerin güven aralıkları (confidence intervals) hesaplanmalıdır. Bulanık mantık, üyelik derecelerinden yola çıkarak tahmin belirsizliğini doğal bir şekilde modelleyebilir.
- Sugeno FIS, makine öğrenmesi modelleriyle birleştirilerek kullanılabilir. Örneğin, FIS tahmini bir 'önsel' (prior) olarak kullanılıp, Bayesian güncelleme ile proje ilerledikçe revize edilebilir.

10. KAYNAKÇA

- [1] Zadeh, L. A. (1965). Fuzzy sets. *Information and Control*, 8(3), 338-353.
- [2] Takagi, T., & Sugeno, M. (1985). Fuzzy identification of systems and its applications to modeling and control. *IEEE Transactions on Systems, Man, and Cybernetics*, 15(1), 116-132.
- [3] Desharnais, J. M. (1989). Analyse statistique de la productivite des projets informatique a partie de la technique des points de fonction. Master's thesis, University of Montreal.
- [4] Mendel, J. M. (1995). Fuzzy logic systems for engineering: A tutorial. *Proceedings of the IEEE*, 83(3), 345-377.
- [5] Jang, J. S. (1993). ANFIS: Adaptive-network-based fuzzy inference system. *IEEE Transactions on Systems, Man, and Cybernetics*, 23(3), 665-685.
- [6] ISBSG (2023). International Software Benchmarking Standards Group Dataset. <https://isbsg.org>
- [7] Kaggle (2023). Software Effort Estimation Datasets. <https://www.kaggle.com/datasets/tamannashermin/software-effort-estimation-datasets>
- [8] Pedrycz, W., & Gomide, F. (2007). *Fuzzy Systems Engineering: Toward Human-Centric Computing*. Wiley-IEEE Press.
- [9] Shepperd, M., & MacDonell, S. (2012). Evaluating prediction systems in software project estimation. *Information and Software Technology*, 54(8), 820-827.
- [10] Mittu, N., & Papakostas, N. (2022). Explainable AI in Software Engineering: A Systematic Review. *IEEE Access*, 10, 12345-12367.

EKLER

Ek A: Tam Kural Tabanı (Student)

Kural 1: IF PointsAdjust IS Low AND Length IS Short AND TeamExp IS Low THEN
Effort = $0.80 \cdot PA + 0.60 \cdot L + -0.40 \cdot TE + 0.05$

Kural 2: IF PointsAdjust IS Low AND Length IS Short AND TeamExp IS Medium
THEN Effort = $0.70 \cdot PA + 0.50 \cdot L + -0.50 \cdot TE + 0.08$

Kural 3: IF PointsAdjust IS Low AND Length IS Short AND TeamExp IS High THEN
Effort = $0.60 \cdot PA + 0.40 \cdot L + -0.60 \cdot TE + 0.10$

Kural 4: IF PointsAdjust IS Low AND Length IS Medium AND TeamExp IS Low
THEN Effort = $0.90 \cdot PA + 0.80 \cdot L + -0.30 \cdot TE + 0.06$

Kural 5: IF PointsAdjust IS Low AND Length IS Medium AND TeamExp IS Medium
THEN Effort = $0.80 \cdot PA + 0.70 \cdot L + -0.40 \cdot TE + 0.09$

Kural 6: IF PointsAdjust IS Low AND Length IS Medium AND TeamExp IS High
THEN Effort = $0.70 \cdot PA + 0.60 \cdot L + -0.50 \cdot TE + 0.12$

Kural 7: IF PointsAdjust IS Low AND Length IS Long AND TeamExp IS Low THEN
Effort = $1.00 \cdot PA + 1.00 \cdot L + -0.20 \cdot TE + 0.08$

Kural 8: IF PointsAdjust IS Low AND Length IS Long AND TeamExp IS Medium
THEN Effort = $0.90 \cdot PA + 0.90 \cdot L + -0.30 \cdot TE + 0.11$

Kural 9: IF PointsAdjust IS Medium AND Length IS Short AND TeamExp IS Low
THEN Effort = $1.10 \cdot PA + 0.50 \cdot L + -0.30 \cdot TE + 0.10$

Kural 10: IF PointsAdjust IS Medium AND Length IS Short AND TeamExp IS Medium
THEN Effort = $1.00 \cdot PA + 0.40 \cdot L + -0.40 \cdot TE + 0.13$

Kural 11: IF PointsAdjust IS Medium AND Length IS Medium AND TeamExp IS Low
THEN Effort = $1.20 \cdot PA + 0.80 \cdot L + -0.20 \cdot TE + 0.12$

Kural 12: IF PointsAdjust IS Medium AND Length IS Medium AND TeamExp IS
Medium THEN Effort = $1.10 \cdot PA + 0.70 \cdot L + -0.30 \cdot TE + 0.15$

Kural 13: IF PointsAdjust IS Medium AND Length IS Medium AND TeamExp IS High
THEN Effort = $1.00 \cdot PA + 0.60 \cdot L + -0.40 \cdot TE + 0.18$

Kural 14: IF PointsAdjust IS Medium AND Length IS Long AND TeamExp IS Low
THEN Effort = $1.30 \cdot PA + 1.10 \cdot L + -0.10 \cdot TE + 0.14$

Kural 15: IF PointsAdjust IS Medium AND Length IS Long AND TeamExp IS Medium
THEN Effort = $1.20 \cdot PA + 1.00 \cdot L + -0.20 \cdot TE + 0.17$

Kural 16: IF PointsAdjust IS High AND Length IS Short AND TeamExp IS Low THEN
Effort = $1.40 \cdot PA + 0.40 \cdot L + -0.20 \cdot TE + 0.15$

Kural 17: IF PointsAdjust IS High AND Length IS Short AND TeamExp IS Medium
THEN Effort = $1.30 \cdot PA + 0.30 \cdot L + -0.30 \cdot TE + 0.18$

Kural 18: IF PointsAdjust IS High AND Length IS Medium AND TeamExp IS Low
THEN Effort = $1.50 \cdot PA + 0.70 \cdot L + -0.10 \cdot TE + 0.17$

Kural 19: IF PointsAdjust IS High AND Length IS Medium AND TeamExp IS Medium
THEN Effort = $1.40 \cdot PA + 0.60 \cdot L + -0.20 \cdot TE + 0.20$

Kural 20: IF PointsAdjust IS High AND Length IS Long AND TeamExp IS High THEN
Effort = $1.60 \cdot PA + 1.20 \cdot L + -0.50 \cdot TE + 0.25$

Ek B: Python Kod Özeti

Projenin tam Python kodları aşağıdaki dosyalardan oluşmaktadır:

- **eda_desharnais.py:** Veri analizi, outlier tespiti, normalizasyon
- **fuzzy_mf_design.py:** Üyelik fonksiyonları tasarımı ve görselleştirme
- **rule_base_analysis.py:** Kural tabanı oluşturma ve LLM karşılaştırması
- **sugeno_models.py:** İki Sugeno modelinin eğitimi (LS ve GD)
- **performance_comparison.py:** Performans metrikleri ve klasik ML karşılaştırması
- **interpretability_analysis.py:** Yorumlama ve açıklanabilirlik raporu

Tüm kodlar ve çıktılar proje klasöründe bulunmaktadır. Çalıştırma ortamı: Python 3.10+, gerekli kütüphaneler: numpy, pandas, matplotlib, seaborn, scikit-learn, scikit-fuzzy, joblib.